FRAMEWORK UNIFICADO

Apache Spark

Processamento Distribuído de Dados em Larga Escala

ETL · Streaming · Machine Learning · Análise de Risco

Professor: Benir Falcão Pistille

Framework
Apache Spark 4.x

Fev-2026

Agenda

01 Introdução e Arquitetura

Fundamentos do Apache Spark, arquitetura master-worker, RDDs e DAG

02 Processamento Batch e Streaming

Spark SQL, Structured Streaming, micro-batch e real-time processing

03 ETL e Machine Learning

Pipelines de ETL, MLlib, algoritmos de ML e casos de uso

04 Análise de Risco

Aplicações financeiras, detecção de fraudes, VaR e conformidade

05 Tecnologias Emergentes

Spark 4.0, Delta Lake, Iceberg, Kubernetes, Flink, Ray e tendências 2025-2026

CAPÍTULO 01

Introdução e Arquitetura

Fundamentos do Apache Spark e componentes principais

Apache Spark: Visão Geral e Arquitetura

O que é Apache Spark?

Motor de processamento distribuído open-source para big data, oferecendo processamento em memória 100x mais rápido que MapReduce.

Scala/Java	Python/R
APIs Nativas	Bindings

Adoção Enterprise

70% das Fortune 500 empresas utilizam Spark

Arquitetura Master-Worker

1. **Driver Program**
   Coordenador central com SparkContext. Converte código em plano de execução DAG.
2. **Cluster Manager**
   Aloca recursos: Standalone, YARN, Mesos ou Kubernetes.
3. **Executors**
   Processos worker que executam tarefas e armazenam dados em cache.
4. **Worker Nodes**
   Máquinas do cluster que hospedam executores.

Spark 4.0 NEW

390+ desenvolvedores contribuíram · 5.100+ issues resolvidas

Lazy Eval | Data Locality | In-Memory

RDDs, DAG e Abstrações de Dados

Resilient Distributed Datasets

RDDs são a estrutura de dados fundamental do Spark - coleções imutáveis e distribuídas de objetos.

Tolerância a Falhas
Via lineage - recomputação automática

Imutabilidade
Transformações criam novos RDDs

Particionamento
Distribuído em partições

Operações
Transformations e Actions

Directed Acyclic Graph

DAG representa sequência de transformações aplicadas aos RDDs, permitindo otimização do plano de execução.

Stages
Divisão por shuffle

Tasks
Unidades paralelas

Evolução das APIs

L1 **RDDs (2012)**
API funcional de baixo nível

L2 **DataFrames (2015)**
API estruturada com otimização

L3 **Datasets (2016)**
Type-safe + otimização

✓ **Recomendação Atual**
DataFrames/Datasets para performance

Otimizações Principais

- **Lazy Evaluation:** Construção de plano otimizado
- **Data Locality:** Computação próxima aos dados
- **In-Memory:** Cache de resultados intermediários

CAPÍTULO 02

Processamento Batch e Streaming

Processamento unificado de dados em tempo real e batch

Spark SQL e Structured Streaming

Spark SQL

Módulo para processamento estruturado com APIs SQL e DataFrame, integrando-se perfeitamente com o ecossistema Spark.

Catalyst Optimizer

Otimização automática de consultas

Tungsten Engine

Execução off-heap com code generation

Operações Suportadas

SELECT | JOIN | GROUP BY | WINDOW | UDFs

Structured Streaming

Evolução do Spark Streaming tratando streams como tabelas contínuas com semântica exactly-once.

Micro-Batch Architecture

Processamento em janelas de tempo

Event-Time Processing

Watermarks para dados atrasados

Real-Time Mode (Spark 4.1)

NEW

Latência de milissegundos com trigger continuous

Componentes do Streaming

DStreams
Sequência de RDDs

Sources
Kafka, Kinesis, Flume

Transformations
map, filter, reduce

Output Ops
Console, DBs, dashboards

CAPÍTULO 03

ETL e Machine Learning

Pipelines de dados e ML escalável

DATA PROCESSING

ETL com Spark e MLlib

Pipelines ETL

Spark é a escolha dominante para pipelines de ETL em larga escala, oferecendo integração com múltiplas fontes.

Leitura de Dados

HDFS, S3, JDBC, NoSQL, Kafka

Transformações

Limpeza, enriquecimento, agregação

Escrita Otimizada

Particionamento, bucketing, Parquet

MLlib: Machine Learning

Biblioteca de ML escalável com algoritmos distribuídos e Pipeline API para workflows.

Classificação
Logistic Regression, Random Forests

Regressão
Linear, Decision Trees

Clustering
K-means, Gaussian Mixture

Recomendação
ALS Collaborative Filtering

Casos de Uso

- Detecção de fraudes
- Sistemas de recomendação
- Segmentação de clientes

VARIANT Type (Spark 4.0)

NEW

Tipo para dados semi-estruturados (JSON) com performance 8x superior.

Spark Connect

Arquitetura client-server com cliente Python de 1.5 MB.

CAPÍTULO 04

Análise de Risco

Aplicações financeiras e gestão de risco

Análise de Risco Financeiro com Spark

Aplicações Financeiras

Risco de Crédito

Modelagem preditiva com MLlib para scoring

Detecção de Fraudes

Análise em tempo real de transações

Value at Risk (VaR)

Cálculo de risco de portfólios

Compliance

Conformidade Basel III, CCAR

Vantagens

Performance

Processamento em memória 100x mais rápido

Escalabilidade

Escalabilidade horizontal

Tempo Real

Streaming com latência baixa

Tolerância

Fault tolerance automática

Case: Banco Global

Detecção de fraudes em 200ms

Processamento de **milhões de transações/dia** com Spark Streaming + MLlib.

Integração ML + Streaming

- Treinamento batch
- Deploy em streaming
- Predições em tempo real

CAPÍTULO 05

Tecnologias Emergentes

Ecossistema e tendências para 2025-2026

Ecossistema Spark 2025-2026

Spark 4.0 Highlights

ANSI SQL Mode — DEFAULT
Compliance padrão com SQL ANSI

VARIANT Type — 8x
Dados semi-estruturados otimizados

SQL UDFs & PIPE Syntax
Funções SQL e operador |>

Structured Logging
Logs em formato JSON

Delta Lake vs Iceberg

Delta Lake
Spark-optimized, ACID, time travel

Apache Iceberg
Engine-agnostic, REST catalog

Kubernetes

Orquestração Nativa
Suporte nativo a K8s com RBAC

Segurança
Secrets, NetworkPolicies

Storage
Persistent Volumes

Frameworks Complementares

Apache Flink — ms
True streaming, latência ms

Ray — AI
Distributed AI, GPUs

Databricks — Managed
Plataforma gerenciada, AutoML

CONCLUSÃO AULA

Apache Spark continua dominando o processamento distribuído

Framework unificado que evolui constantemente para atender demandas de baixa latência, ML e governança

Recomendações

1. **Spark 4.0** para novos projetos
2. **Real-Time Mode** para latência crítica
3. **Delta Lake/Iceberg** para governança
4. **Kubernetes** para orquestração

Quando Usar Cada Tecnologia

Apache Spark
Batch, ETL, ML, analytics (latência segundos)

Apache Flink
True streaming, CEP, latência ms

Ray
Distributed AI, RL, GPU workloads

Framework
Apache Spark 4.x

Atualização
2025-2026