
MINIO

Plataforma Unificada de Processamento de Dados

Arquitetura para ETL, Machine Learning, IA
e Streaming de Eventos em Larga Escala

ETL

ML / IA

STREAMING

LARGA ESCALA

Stack Tecnológico

Infraestrutura de Ciência de Dados e Big Data

Escolha guiada por alta performance, baixa latência e ecossistema completo



Apache Spark
Processamento Distribuído

Framework unificado para processamento de dados em larga escala (batch e near real-time)

Casos: ETL, ML, análise de risco



Apache Flink
Processamento em Tempo Real

Framework streaming-first com baixa latência e estado consistente (stateful)

Casos: Detecção de fraudes, anomalias, risco



Apache Kafka
Mensageria/Ingestão

Plataforma de streaming de eventos distribuída, alta vazão e tolerante a falhas

Casos: Transações, logs, cotações



MinIO
Data Lake

Armazenamento S3-compatible para dados brutos e processados



PostgreSQL
Data Warehouse

Banco relacional robusto para BI e relatórios estruturados



Apache Airflow
Orquestração

Gestão de workflows complexos e pipelines de dados



Python + ML
Análise e ML

Pandas, Scikit-learn, TensorFlow, PyTorch

| AGENDA

01

Fundamentos do MinIO

Object Storage, buckets, objetos e compatibilidade S3

02

Arquitetura e Escalabilidade

AIStor, arquitetura exabyte-scale, deployment e segurança

03

Streaming de Eventos

Kafka, Spark Streaming, Flink e integração com MinIO

04

ETL e Data Lakehouse

Pipelines ETL, arquitetura medallion e open table formats

05

ML, IA e Data Mining

Pipelines MLOps, modelos, datasets e mineração de dados

06

Tecnologias Emergentes

ExaPOD, Polaris, Paimon, XTable e tendências 2025-2026

AULA dividida em 6 módulos com conteúdo teórico, arquitetura e casos reais

01

FUNDAMENTOS DOMÍNIO

Object Storage, buckets, objetos e compatibilidade S3



| O Que e Object Storage e Por Que MinIO?

Object Storage armazena dados como **objetos** — cada um com:

- **BLOB**: dados binarios (imagem, video, log)
- **Metadados**: descritores ricos do objeto
- **ID Unico Global**: identificador imutavel

Diferente de file systems hierarquicos, nao ha limitacao de aninhamento

Por Que MinIO?

- **100% S3-Compatible** — API REST completa
- **Alto Desempenho** — otimizado para NVMe
- **Cloud-Native** — Kubernetes-native
- **Open Source** — AGPL v3
- **Software-Defined** — hardware padrao
- **Focus S3** — vs Ceph (multi-paradigma)

Exemplos de BLOBs em Object Storage:



Imagens / Videos



Backups / Logs



Modelos ML / IA



Datasets / Parquet



Audio / Media

| Buckets, Prefixos e a API S3

Conceitos Fundamentais

Bucket — container logico para objetos, similar a um dominio DNS. Nao ha limite de objetos por bucket.

Prefixo — simula hierarquia dentro do bucket:

`dados/2025/janeiro/vendas.parquet`

Objeto — unidade atomica de storage: dados + metadados + ID unico.

Compatibilidade S3 Total

- Endpoints REST: PUT, GET, LIST, DELETE
- Autenticacao: Access Key + Secret Key
- Objetos imutaveis com versionamento
- SDKs: Python, Go, Java, JS, .NET
- Drop-in replacement para AWS S3

Modos de Deployment



Docker Container

`docker run minio/minio`



Bare Metal

Servidor fisico/VM



Kubernetes


Helm / Operator

Console Web: Interface grafica em localhost:9090 — secured com root user/password por padrao


02

ARQUITETURA E ESCALABILIDADE

AIStor, arquitetura exabyte-scale, deployment e segurança



| Arquitetura AIStor: Gateway-Free e Stateless



ExaPOD (2025): Arquitetura de referencia para exascale AI — blocos modulares de 1EB com Intel, Solidigm e Supermicro. TCO previsivel, sovereign deployment.

Fonte: MinIO Cloud Field Day 23, BusinessWire Nov 2025

| Seguranca, Replicacao e Deployment

Seguranca Nativa

- TLS 1.2+ — criptografia em transito
- AES-256-GCM — encryption at rest
- IAM Policies — controle de acesso granular
- Bucket Policies — regras por bucket
- Object Immutability — WORM compliance
- Erasure Coding — protecao sem mirror
- Server-Side Replication — sync/async

Best Practices K8s

- Modo **Distributed** em producao
- Erasure coding com **4+ nos**
- **Resource Limits** para prevenir OOM
- **External Secrets** (nao hardcode)
- TLS para dados em transito
- **Backups Regulares** — DR
- **Monitoramento** — alertas pre-full

Tipos de Deployment

Standalone — Desenvolvimento/testes

Distributed — Producao multi-no

Gateway — Frontend para NAS/SAN

Fonte: MinIO Documentation, OneUptime Blog 2026

03

STREAMING DE EVENTOS DISTRIBUIDO

Kafka, Spark Streaming, Flink e integracao com MinIO para alta vazao



| Kafka + Spark Structured Streaming + MinIO



Plataforma de streaming de eventos distribuida:

- Alta disponibilidade
- Throughput massivo
- Escalabilidade horizontal
- Particoes replicadas



Spark Structured Streaming

Processamento contínuo baseado em Spark SQL:

- Fault-tolerance
- Exactly-once semantics
- Event time processing
- State management




MinIO Data Lake

Storage para streaming data lakes:

- S3 API completa
- Checkpointer otimizado
- Iceberg Tables nativo
- Alta performance

Fluxo de Dados



Casos de Uso

- Analytics em tempo real
- Deteccao de fraude
- IoT Data Ingestion

Fonte: MinIO Blog—Spark Structured Streaming with Kafka and MinIO

| Apache Flink: Stream Processing Avancado

Apache Flink é o motor de processamento de streams padrão de fato para **exactly-once processing**.

Arquitetura:


- **JobManager** — coordenação e scheduling
- **TaskManagers** — execução paralela

Checkpointing: snapshots distribuídos garantem exactly-once semantics e fault-tolerance automática.

Diferenciais do Flink

- Latência **sub-segundo**
- Streaming e **batch** unificados
- **State management** integrado
- **Event time** processing nativo
- Conector **Iceberg** nativo

Pipeline: Kafka -> Flink -> Iceberg -> MinIO



Fonte: Medium — Build a Streaming Data Lakehouse with Flink, Kafka, Iceberg

04

ETL E DATA LAKEHOUSE


Pipelines ETL, architettura medallion e open table formats



| Arquitetura Medallion: Bronze, Silver, Gold



Pipeline ETL com Spark + Airflow + MinIO



Data Quality: Checks entre camadas — nulls, duplicates, schema conformity — antes de downstream use.

Fonte: AI-Lakehouse.com, Medium — Build Data Engineering Pipeline

| Open Table Formats: Iceberg vs Delta vs Hudi

Feature	Apache Iceberg	Delta Lake	Apache Hudi
Arquitetura	Spec-first, engine-agnostic	Spark-native, log-based	Record-level, upsert-optimized
Partitioning	Hidden + Evolution	Liquid Clustering	Physical + Bucket Index
Engines	Spark, Flink, Trino, Snowflake	Spark, Databricks	Spark, Flink, Hive
Time Travel	Snapshot-based	Version-based	Timeline-based
CDC / Upserts	COW + MOR	COW + Deletion Vectors	Native (MOR)
Adocao 2025	Padrao de fato	Databricks ecosystem	CDC / Streaming niche
Quando Usar	Multi-engine, cloud-native	Databricks-only	High-volume CDC/upserts

Interoperabilidade entre Formatos

Apache XTable: Cross-format translation (Iceberg <-> Delta <-> Hudi) — guerras de formatos acabando.

Delta UniForm: Gera metadata Iceberg junto com Delta para leitura multi-engine.

Fonte: Dremio Blog, Scalefree.com, Onehouse.ai — 2025

| Ecosystem Lakehouse Completo com MinIO



Storage Layer — MinIO (S3-compatible) — Bronze / Silver / Gold

Parquet / ORC / Avro



Table Format + Catalog — Iceberg / Delta / Hudi + Nessie / Polaris

ACID / Time Travel / Schema Evolution



Query + Processing — Trino / Spark / Presto / Flink

SQL Federado / Batch / Streaming



Ingestion — Airbyte / Kafka Connect



Orchestration — Airflow / Argo Workflows



BI / Viz — Superset / Metabase / Grafana



Governance — DataHub / Keycloak / RBAC

Kubernetes: Plataforma unificadora — namespaces para isolamento, Operators para Spark/Kafka, Prometheus + Grafana + Loki para observabilidade.

Fonte: StudioTVAI — Complete Lakehouse Tutorial

05

ML, IA E DATA MINING

Pipelines MLOps, modelos, datasets e mineracao de dados



| MinIO como Data Foundation para ML e IA

Cada grande LLM foi construido usando **object storage**. MinIO AIStor e o data foundation para AI enterprise — throughput massivo para manter GPUs alimentadas.

2.2 TiB/s

Throughput para clusters GPU

1.35 EB

Deployment real autonomo

6 PB/dia

Ingestao diaria de dados

Casos de Uso AI/ML no MinIO



Autonomous Driving

Treinamento de modelos com 1.35 EB de dados de frota global



Cybersecurity

1.25 PB — repatriado da AWS, margem +2-3%



Fintech Payments

30 PB, 500M merchants, bilhoes de arquivos pequenos

Integracao Nativa com Frameworks

PyTorch

TensorFlow

Hugging Face

Ray

MLflow

DVC

Fonte: MinIO Blog — Exascale AI, CubePath — ML Model Storage

Pipeline MLOps e Data Mining



Data Mining e Tecnicas

- **Classificacao** — categorizacao de dados
- **Clustering** — agrupamento por similaridade
- **Associacao** — descoberta de padroes
- **Anomalias** — deteccao de outliers

RAG Applications

Lakehouse data + embeddings + LLM serving (vLLM). Dados corporativos armazenados no MinIO alimentam aplicacoes de IA generativa.

Fonte: MLOps.org, StudioTVAI — Lakehouse Architecture

06

TECNOLOGIAS EMERGENTES E FUTURO

ExaPOD, Polaris, Paimon, XTable e tendencias 2025-2026



| Tecnologias Emergentes no Ecossistema MinIO

2025

MinIO ExaPOD

Arquitetura de referencia para exascale AI. Blocos modulares de 1EB com Intel, Solidigm e Supermicro. TCO previsivel.

NEW

Apache Polaris

Catalogo open-source para Iceberg. REST API, OAuth2, multi-tenant. Gerenciamento de catalogos universal.

RISING

Apache Paimon

Streaming lakehouse format nativo para Flink. LSM-tree based. Otimizado para write-intensive workloads.

UNIFY

Apache XTable

Cross-format translation: Iceberg <-> Delta <-> Hudi. As guerras de formatos de tabela estao acabando. Vendor lock-in eliminado.

BETA

DuckLake

Novo formato com metadata em SQL database. Multi-table transactions. Developer-friendly. Integracao com DuckDB.

Tendencias 2025-2026

- Convergencia de formatos
- DLMS emergence
- AI-native storage
- Sovereign AI / on-prem
- Exascale economics

Fonte: BusinessWire Nov 2025, DataLakehouseHub—Ultimate Guide to Open Table Formats

Conclusão da Aula!

01

Fundamentos do MinIO

Object Storage, buckets, objetos e compatibilidade S3

02

Arquitetura e Escalabilidade

AIStor, arquitetura exabyte-scale, deployment e segurança

03

Streaming de Eventos

Kafka, Spark Streaming, Flink e integração com MinIO

04

ETL e Data Lakehouse

Pipelines ETL, arquitetura medallion e open table formats

05

ML, IA e Data Mining

Pipelines MLOps, modelos, datasets e mineração de dados

06

Tecnologias Emergentes

ExaPOD, Polaris, Paimon, XTable e tendências 2025-2026

Exascale

Performance

Open Source

Arquitetura Aberta

AI-Ready

Ecossistema em Evolução

MinIO e a base de dados unificada para processamento em larga escala

— de streaming a inteligência artificial —

Professor Benir Falcão Pistille
Maio/2026