




Avaliação Diagnóstica

Apache Kafka

Infraestrutura, Processamento de Dados em Média e Larga Escala, ETL, Machine Learning, APIs e Tecnologias Emergentes


Nome: Arthur Nunes
Bruno Araujo
Caio Corr 

EQUIPE 1

Professor Benir Falc o Pistille

Vers o 2

Abril 2026



Sumario

Clique com o botão direito no sumario e selecione "Atualizar Campo" para atualizar os números de pagina

Sumario.....	2
Etapa 1: Fundamentos de Infraestrutura Kafka	3
Etapa 2: Arquitetura e Fluxos de Dados	7
Etapa 3: ETL, APIs e Integracao	10
Etapa 4: Machine Learning, Data Mining e Tecnologias Emergentes	14

Etapa 1: Fundamentos de Infraestrutura Kafka

Esta etapa aborda conceitos fundamentais de infraestrutura do Apache Kafka, incluindo arquitetura, brokers, tópicos, partições, replicação e o modo KRaft.

Exercício 1

Considerando a arquitetura do Apache Kafka apresentada na Figura 1, qual componente é responsável por armazenar fisicamente os registros (logs) de um tópico e atuar como ponto central de comunicação entre producers e consumers?




Figura 1: Diagrama de referencia

- A) ZooKeeper - coordena a eleição de líderes e metadados.
- B) Producer - envia dados para os tópicos.
- C) Broker - armazena logs e gerencia requisições de leitura/escrita.
- D) Schema Registry - valida esquemas de dados.

Exercício 2

Analisando o fluxograma logico da Figura 2, qual e a função do estágio 'Buffer (Topic Kafka)' no pipeline de processamento?




Figura 2: Diagrama de referencia

- A) Executar transformações complexas nos dados em tempo real.
- ☒ B) Armazenar temporariamente os dados como fila durável, desacoplando producers de consumers.
- C) Aplicar modelos de machine learning para predição.
- D) Enviar dados diretamente para o Data Lake.

Exercício 3

Na arquitetura Kafka com KRaft (Kafka Raft), eliminando a dependência do ZooKeeper, qual e a principal vantagem operacional para o gerenciamento de metadados do cluster?

- A) Redução da latência de rede entre producers e consumers.
- ☒ B) Simplificação da arquitetura, menor overhead e recuperação mais rápida de falhas de metadados.
- C) Aumento automático do número de partições por tópico.
- D) Suporte nativo a transações SQL em tópicos.

Exercício 4

Observando a Figura 6, que ilustra a distribuição de partições e réplicas entre brokers, qual afirmação sobre a replica identificada com '(L)' está correta?




Figura 4: Diagrama de referencia

- A) Indica uma réplica em sincronização (In-Sync Replica).
- ☒ B) Identifica a réplica líder, responsável por todas as operações de leitura e escrita da partição.
- C) Sinaliza uma réplica obsoleta que será removida.
- D) Representa uma partição vazia sem registros.

Exercício 5

Em um cluster Kafka com fator de replicação 3 e min.insync.replicas=2, o que acontece se o broker líder de uma partição falhar e apenas 1 replica permanecer sincronizada?

- A) A produção continua normalmente para essa partição.
- B) O cluster elege automaticamente uma nova partição em um broker diferente.
- ☒ C) Operações de produção configuradas com acks=all falharão até que uma nova ISR seja estabelecida.
- D) Os consumers começam a ler diretamente do producer.

Exercício 6

Qual configuração do broker Kafka determina por quanto tempo os registros serão retidos em um tópico, independentemente de já terem sido consumidos?

- A) max.poll.records
- ☒ B) retention.ms ou retention.bytes
- C) session.timeout.ms
- D) fetch.min.bytes

Exercício 7

No contexto de particionamento de tópicos Kafka, qual estratégia garante que todas as mensagens com a mesma chave (key) sejam sempre direcionadas para a mesma partição?

- A) Round-robin partitioning
- B) Sticky partitioning
- ☒ C) Hash-based partitioning (murmur2 da chave)
- D) Random partitioning

Exercício 8

Qual é o papel do 'Controller' em um cluster Kafka operando no modo KRaft, conforme ilustrado na arquitetura da Figura 1?




Figura 8: Diagrama de referência

- A) Receber requisições HTTP de clientes externos.
- ☒ B) Gerenciar metadados, eleição de líderes e balanceamento de partições.
- C) Compactar logs automaticamente para economizar espaço.
- D) Converter dados entre formatos Avro e JSON.

Etapa 2: Arquitetura e Fluxos de Dados

Esta etapa explora fluxos de dados, particionamento, garantias de entrega, processamento de streams e tolerância a falhas em pipelines Kafka.

Exercício 9

Considerando o fluxograma logico da Figura 2, qual mecanismo representa o caminho alternativo para mensagens que falham no processamento ou na validação?




Figura 9: Diagrama de referencia

- A) Kafka Streams State Store
- ☒ B) Dead Letter Queue (DLQ)
- C) Schema Registry Fallback
- D) Offset Commit Buffer

Exercício 10

Em um pipeline Kafka de media escala (100K msg/s), qual combinaçao de configurações de producer oferece o melhor equilíbrio entre durabilidade e throughput?

- A) acks=0, retries=0, batch.size=16384
- B) acks=all, retries=2147483647, enable.idempotence=true
- C) acks=1, retries=3, compression.type=none
- ☒ D) acks=all, retries=10, enable.idempotence=true, compression.type=lz4

Exercício 11

A Figura 6 demonstra a distribuição de tópicos e partições entre brokers. Se um tópico 'Pedidos' possui 6 partições e 3 replicas, quantas cópias físicas totais de partições existem no cluster?




Figura 11: Diagrama de referencia

- A) 6 cópias
- B) 9 cópias
- ☒ C) 18 cópias
- D) 3 cópias

Exercício 12

Qual conceito do Kafka Streams permite realizar agregações (como soma ou contagem) mantendo estado local entre eventos de uma mesma chave?

- A) Global Table
- ☒ B) KStream com Stateful Operation e State Store
- C) Punctuator sem estado
- D) Consumer Group Rebalance

Exercício 13

Em um cenário de larga escala (milhões de mensagens por segundo), o 'Tiered Storage' (armazenamento em camadas) do Kafka 3.0+ oferece qual benefício principal?

- A) Elimina a necessidade de brokers e utiliza apenas clientes P2P.
- ☒ B) Permite mover dados antigos para object storage (S3) reduzindo custo e mantendo acesso via API Kafka.
- C) Substitui o Schema Registry por um sistema interno de serialização.
- D) Aumenta automaticamente o número de partições conforme o volume.

Exercício 14

Qual configuração no consumer garante que, em caso de falha, o consumer retome a leitura a partir da última mensagem confirmada (committed offset)?

- A) `auto.offset.reset=latest`
- ☒ B) `enable.auto.commit=true` com intervalo baixo
- C) `isolation.level=read_committed`
- D) `max.poll.interval.ms` alto

Exercício 15

A 'Exactly-Once Semantics' (EOS) no Kafka é alcançada principalmente pela combinação de quais três mecanismos?

- A) `acks=1`, `retries=0` e batching desativado
- ☒ B) idem potência do producer, transações entre producer e consumer, e `isolation.level=read_committed`
- C) Particionamento aleatório, compactação de logs e Schema Registry
- D) ZooKeeper locks, replica síncrona e auto-commit

Exercício 16

No processamento de eventos em larga escala, a técnica de 'Event Time Processing' em Kafka Streams diferencia-se do 'Processing Time' porque:

- A) Utiliza o relógio do broker para ordenação, ignorando timestamps dos eventos.
- ☒ B) Ordena e agrega registros baseado no timestamp embutido no evento, mesmo que cheguem fora de ordem.
- C) Processa dados em lotes diários ao invés de tempo real.
- D) Desativa o log compaction para preservar histórico completo.

Etapa 3: ETL, APIs e Integração

Esta etapa foca em ETL unificado, Kafka Connect, REST Proxy, Schema Registry e integração com sistemas externos via APIs.

Exercício 17

Analisando a Figura 3, que ilustra uma arquitetura ETL unificada com Kafka, qual componente é responsável por ingerir dados de sistemas legados (como bancos SQL) sem necessidade de código customizado?




Figura 17: Diagrama de referencia

- A) Kafka Streams
- ☒ B) Kafka Connect Source
- C) ksqlDB
- D) Producer API

Exercício 18

Qual é a função do 'Schema Registry' no ecossistema Kafka, especialmente quando combinado com o formato Avro?




Figura 18: Diagrama de referência

- A) Compactar dados para reduzir uso de rede.
- ☒ B) Armazenar e versionar esquemas, garantir compatibilidade e permitir serialização/de serialização segura entre producers e consumers.
- C) Gerenciar offsets de consumo em um banco relacional.
- D) Roteamento de mensagens entre clusters multi-region.

Exercício 19

A ferramenta 'ksqlDB' permite executar consultas SQL contínuas sobre streams Kafka. Em um pipeline ETL, qual é seu principal caso de uso?

- A) Substituir completamente o banco de dados transacional.
- ☒ B) Criar filtros, joins e agregações em tempo real sem necessidade de codificar Java/Scala.
- C) Armazenar dados em disco permanentemente.
- D) Gerenciar configurações de segurança SSL/TLS.

Exercício 20

O 'Kafka REST Proxy' (Figura 5) possibilita que clientes não-nativos interajam com o Kafka. Qual restrição típica aplica-se a essa interface?




Figura 20: Diagrama de referencia

- A) Suporta apenas produção, não consumo.
- Possui maior latência comparado ao protocolo binário nativo e menor throughput por conexão.
- C) Não suporta formato JSON.
- D) Exige ZooKeeper em todas as requisições.

Exercício 21

Em um pipeline ETL Kafka, a 'Single Message Transform' (SMT) do Kafka Connect serve para:

- A) Realizar machine training nos dados em trânsito.
- Aplicar transformações leves (filtros, mascaramento, renomeação) antes de entregar ao tópico ou ao sink.
- C) Compactar partições antigas automaticamente.
- D) Balancear carga entre múltiplos clusters.

Exercício 22

Qual protocolo de serialização, comumente usados com Schema Registry, oferece melhor compatibilidade evolutiva e menor tamanho de payload comparado ao JSON raw?

- A) XML
- ☒ B) Avro ou Protobuf
- C) CSV
- D) YAML

Exercício 23

A Figura 5 apresenta tecnologias emergentes integradas ao Kafka. Dentre elas, o 'Kafka on Kubernetes (K8s)' utiliza operadores (ex: Strimzi) para:




Figura 23: Diagrama de referencia

- A) Substituir o protocolo TCP por HTTP/3.
- ☒ B) Automatizar provisionamento, upgrade, rebalancing e recuperação de brokers em containeres.
- C) Eliminar a necessidade de tópicos e partições.
- D) Converter dados binários em texto plano automaticamente.

Etapa 4: Machine Learning, Data Mining e Tecnologias Emergentes

Esta etapa aborda integração de Kafka com Machine Learning, Data Mining, análise preditiva e tecnologias emergentes no processamento de dados.

Exercício 24

Conforme a arquitetura da Figura 4, em um pipeline Kafka + ML em tempo real, qual é o papel da camada 'Feature Engineering (Kafka Streams)'?




Figura 24: Diagrama de referencia

- A) Treinar o modelo neural network diretamente nos brokers.
- Extrair, transformar e enriquecer features a partir de streams brutos antes da inferência.
- C) Armazenar os pesos do modelo em um tópico compactado.
- D) Gerar imagens estatísticas para dashboards.

Exercício 25

No contexto de Data Mining em larga escala com Kafka, a técnica de 'Windowing' (janelas temporais) em Kafka Streams é essencial para:

- A) Compactar logs antigos em disco.
- Agrupar eventos em intervalos de tempo definidos (tumbling, hopping, session) para análise de padrões.
- C) Criar backups automáticos do cluster.
- D) Gerenciar senhas de usuários do Schema Registry.

Exercício 26

Qual abordagem permite servir um modelo de machine learning (ex: TensorFlow Serving) consumindo features diretamente de um tópico Kafka para inferência em tempo real?




Figura 26: Diagrama de referencia

- A) Exportar o tópico para CSV e carregar no modelo a cada hora.
- ☒ B) Utilizar um micro serviço consumer que lê features do tópico 'Feature', chama o modelo via gRPC/REST e publica previsões em outro tópico.
- C) Instalar o TensorFlow diretamente dentro do broker Kafka.
- D) Desativar o Schema Registry para reduzir overhead.

Exercício 27

A 'Tiered Storage' (Figura 5) é considerada uma tecnologia emergente importante para análise de dados históricos porque:




Figura 27: Diagrama de referencia

- A) Substitui totalmente os Data Lakes tradicionais.
- ☒ B) Permite manter anos de dados em storage econômico (S3) enquanto os brokers retêm apenas dados recentes de alta performance.
- C) Elimina a necessidade de partições em tópicos.
- D) Converte automaticamente logs em gráficos de visualização.

Exercício 28

Em cenários de Data Mining, o 'Log Compaction' do Kafka é útil para:

- A) Reduzir a retenção de dados a 24 horas.
- ☒ B) Manter apenas o valor mais recente para cada chave, criando um snapshot lógico útil para lookups e joins.
- C) Criptografar dados em repouso automaticamente.
- D) Balancear carga entre data centers geograficamente distribuídos.

Exercício 29

A tecnologia emergente 'Kafka MirrorMaker 2.0' é utilizada principalmente para:

- A) Compactar mensagens em formato Parquet.
- ☒ B) Replicar tópicos entre clusters Kafka em diferentes data centers ou regiões, com preservação de offsets.
- C) Treinar modelos de NLP diretamente nos tópicos.
- D) Converter protocolos MQTT para AMQP.

Exercício 30

Integrando Kafka com pipelines de MLOps, qual é a vantagem de utilizar um 'Model Registry' (ex: MLflow) em conjunto com tópicos de eventos?

- A) Elimina a necessidade de validação cruzada (cross-validation).
- ☒ B) Permite versionar modelos, rastrear experimentos e garantir reprodutibilidade entre treinamento offline e inferência online via Kafka.
- C) Substitui o ZooKeeper na gestão de metadados do cluster.
- D) Aumenta o tamanho das mensagens Kafka para incluir embeddings completos.

Apache Kafka

Processamento de dados em média e larga escala

Professor Benir Falcão Pistille

Versão 2

Abril 2026

