

APACHE SPARK

Avaliação Diagnóstica de Infraestrutura e Processamento de Dados

ETL | Machine Learning | IA | Data Mining | Streaming | Arquitetura

Professor Benir Falcão Pistille

Equipe: Arthur Nunes
Bruno Araujo
Caio Corrá

Sumario

(Clique com botao direito e selecione 'Atualizar Campo' para atualizar numeros de pagina)

Sumario.....	2
Etapa 1: Fundamentos e Arquitetura	3
Etapa 2: Processamento de Dados (ETL).....	5
Etapa 3: Spark SQL e DataFrames	7
Etapa 4: Streaming e Processamento em Tempo Real	8
Etapa 5: Machine Learning com MLlib.....	10
Etapa 6: Tecnologias Emergentes e Boas Praticas	12
Gabarito - Respostas e Explicacoes	Erro! Indicador não definido.

Etapa 1: Fundamentos e Arquitetura

Esta etapa aborda os conceitos fundamentais da arquitetura Apache Spark, incluindo seus componentes principais, o modelo de execução e a estrutura de processamento distribuído.




Figura 1: Arquitetura Geral do Apache Spark

Exercício 1 [Fundamentos]

Qual componente do Apache Spark é responsável por coordenar a execução de tarefas e manter o estado da aplicação em um cluster?

- A) Worker Node
- B) Executor
- C) Driver Program**
- D) Cluster Manager

Exercício 2 [Fundamentos]

No contexto do Spark, o que representa um RDD (Resilient Distributed Dataset)?

- A) Um banco de dados relacional distribuído
- B) Uma coleção de objetos particionada e tolerante a falhas**
- C) Um sistema de arquivos distribuído
- D) Um serviço de mensageria

Exercicio 3 [Fundamentos]

Qual das seguintes transformacoes NAO e uma 'wide transformation' (requer shuffle)?

- A) groupByKey()
- B) reduceByKey()
- C) map()**
- D) join()




Figura 2: Componentes do Apache Spark

Etapa 2: Processamento de Dados (ETL)

Esta etapa foca em pipelines de ETL (Extract, Transform, Load), operações com DataFrames e otimização de processamento de dados em larga escala.




Figura 3: Pipeline ETL com Apache Spark

Exercício 4 [ETL]

Qual método do `DataStreamReader` é usado para definir o formato da fonte de dados ao ler um arquivo?

- A) `load()`
- B) `format()`**
- C) `option()`
- D) `schema()`

Exercício 5 [ETL]

Em um pipeline Spark, qual operação é recomendada para reduzir o shuffle de dados ao realizar agregações?

- A) `groupBy().sum()`
- B) `reduceByKey()` em RDDs
- C) `aggregateByKey()`
- D) Todas as anteriores**

Exercício 6 [ETL]

Qual formato de arquivo é nativamente otimizado para leitura/escrita no Spark devido à compressão e predicados de pushdown?

- A) CSV
- B) JSON
- C) Parquet**
- D) XML

Exercicio 7 [ETL]

O que e 'predicate pushdown' no contexto do Spark SQL?

- A) Uma tecnica de compressao de dados
- B) Filtragem de dados na fonte antes de carregar no Spark**
- C) Um tipo de particionamento
- D) Um metodo de cache

Etapa 3: Spark SQL e DataFrames

Esta etapa aborda o processamento estruturado de dados usando Spark SQL, DataFrames, Datasets e o Catalyst Optimizer.

Exercício 8 [Spark SQL]

Qual é a principal vantagem de usar DataFrames em vez de RDDs no Spark?

- A) Maior controle sobre o particionamento
- B) Otimização automática pelo Catalyst Optimizer**
- C) Suporte a tipos complexos apenas
- D) Processamento apenas em memória

Exercício 9 [Spark SQL]

O que é o Catalyst Optimizer no Spark SQL?

- A) Um gerenciador de memória
- B) Um otimizador de consultas baseado em regras e custos**
- C) Um sistema de compressão
- D) Um gerenciador de cluster

Exercício 10 [Spark SQL]

Qual método é usado para registrar um DataFrame como uma tabela temporária para consultas SQL?

- A) registerTable()
- B) createOrReplaceTempView()**
- C) toSQL()
- D) cacheTable()

Etapa 4: Streaming e Processamento em Tempo Real

Esta etapa cobre o processamento de fluxo contínuo de dados usando Structured Streaming, incluindo conceitos de event time, watermarks e output modes.




Figura 4: Arquitetura Structured Streaming

Exercício 11 [Streaming]

No Structured Streaming, qual modo de saída garante que apenas novos registros sejam adicionados ao sink?

- A) Complete Mode
- B) Update Mode
- C) Append Mode**
- D) Micro-batch Mode

Exercício 12 [Streaming]

O que é um 'watermark' no contexto do Structured Streaming?

- A) Um tipo de particionamento de dados
- B) Um limite de tempo para aceitar eventos atrasados**
- C) Um método de compressão
- D) Um tipo de checkpoint

Exercício 13 [Streaming]

Qual é a unidade de processamento básica no Structured Streaming?

- A) Batch
- B) Micro-batch**

- C) Record
- D) Partition

Etapa 5: Machine Learning com MLlib

Esta etapa aborda o uso do MLlib para machine learning em escala, incluindo pipelines, transformers, estimators e avaliacao de modelos.




Figura 5: Pipeline de Machine Learning com MLlib

Exercicio 14 [MLlib]

Qual e a diferenca entre um Transformer e um Estimator no MLlib?

- A) Nao ha diferenca
- B) Transformer aplica transformacao; Estimator treina um modelo**
- C) Estimator e apenas para classificacao
- D) Transformer requer menos memoria

Exercicio 15 [MLlib]

Qual classe do MLlib e usada para combinar multiplos estagios de processamento em um pipeline?

- A) PipelineModel
- B) Pipeline**
- C) MLFlow
- D) StageCombiner

Exercicio 16 [MLlib]

Qual tecnica e usada para validacao cruzada no MLlib?

- A) TrainTestSplit

B) CrossValidator

C) KFold

D) GridSearch

Etapa 6: Tecnologias Emergentes e Boas Praticas

Esta etapa final aborda tecnologias emergentes como Delta Lake, Spark 3.x, Adaptive Query Execution, e melhores praticas para producao.




Figura 6: Stack Moderna Apache Spark - Tecnologias Emergentes

DAG (Directed Acyclic Graph) - Execução Spark



Figura 7: DAG e Execucao de Tarefas no Spark

Exercicio 17 [Tecnologias Emergentes]

O que é o Delta Lake e qual problema ele resolve no ecossistema Spark?

- A) Um motor de processamento mais rápido
- B) Uma camada de storage com transações ACID e versionamento**
- C) Um novo sistema de cluster management
- D) Uma linguagem de consulta alternativa

Exercicio 18 [Tecnologias Emergentes]

Qual recurso do Spark 3.x otimiza automaticamente o plano de execução durante a execução da query?

- A) Catalyst Optimizer
- B) Adaptive Query Execution (AQE)**
- C) Tungsten Engine
- D) WholeStageCodegen

Exercicio 19 [Tecnologias Emergentes]

Qual é o propósito do 'Z-Ordering' no Delta Lake?

- A) Compactar arquivos
- B) Colocar informações relacionadas no mesmo conjunto de arquivos para leituras eficientes**
- C) Criar backups automáticos
- D) Sincronizar dados entre clusters

Exercicio 20 [Tecnologias Emergentes]

No contexto de Data Mining com Spark, qual técnica é mais adequada para detecção de anomalias em grandes datasets?

- A) Regressão Linear
- B) K-Means Clustering com distância aos centroides**
- C) Naive Bayes
- D) Decision Trees para classificação binária