

---

# Estudo Técnico Infraestrutura de Dados

Infraestrutura Unificada para Processamento

de Dados em Média e Larga Escala

Análise de Dados | Data Mining | Machine Learning

Professor Benir Falcão Pistille

Versão 1.0

Abril 2026



## Detecção de Fraude e Anomalias em Tempo Real

Análise de Negócio baseado na arquitetura de Data Platform moderna — 5 camadas, 7 ferramentas open-source.

// Prof. Benir Falcão Pistille · 13/04/2026

 4 Aulas

 Grupos

 Documento Word

 Caso real: setor financeiro

### CONTEXTO DO CASO

**<100ms**

Latência de detecção de fraude

**2M+**

Mensagens por segundo no Kafka

**99.5%**

Precisão do modelo de ML

**99.99%**

Disponibilidade da plataforma

## Introdução

Uma grande empresa financeira com 150 localidades de linhas de negócios financeiros e investimentos em nível nacional e no exterior, com 2.000 funcionários e parceiros de sites virtuais de investimentos financeiros. Está ocorrendo diversas transações de dados suspeitas e anomalias através da plataforma de infraestrutura de dados, vamos estudar utilizando análise de dados, mineração de dados e aprendizado de máquina. Dentro desse estudo e objetivo de negócio, como podemos ter visões de transações fraudulentas e anomalias. Estude a plataforma citada abaixo e responder os fluxos de trabalho dessa coleta, armazenamento e transação de dados no contexto de visões de fraudes e anomalias.

## O PROCESSO · 5 CAMADAS DA ARQUITETURA

### Apache Airflow — Orquestração transversal

Gerencia e monitora **todos os pipelines** entre as camadas abaixo: agendamento de jobs, monitoramento visual, gerenciamento de dependências e alertas automáticos.

## FLUXO PONTA A PONTA: TRANSAÇÃO - ORQUESTRAÇÃO

### 01

#### Apache Kafka

##### Camada de Ingestão

#### ENTRADA DOS DADOS

Transações financeiras, logs de acesso e cotações de mercado chegam em tempo real ao Kafka. Alta vazão e tolerante a falhas — nenhuma transação é perdida.

#### DADOS QUE ENTRAM NESTA CAMADA

|                 |           |           |                 |                  |       |                |
|-----------------|-----------|-----------|-----------------|------------------|-------|----------------|
| id_transacao    | valor_R\$ | timestamp | id_conta_origem | id_conta_destino | canal | ip_dispositivo |
| localizacao_GPS |           |           |                 |                  |       |                |

### 02

#### Apache Flink

##### Camada de Streaming

#### PROCESSAMENTO EM TEMPO REAL

Consome o fluxo do Kafka e aplica regras de negócio + modelos de ML de baixa latência. É aqui que a fraude é **detectada em menos de 100ms** — antes mesmo da transação ser aprovada.

#### DADOS PROCESSADOS / GERADOS

|              |                |                    |                 |             |
|--------------|----------------|--------------------|-----------------|-------------|
| score_fraude | regra_acionada | anomalia_detectada | decisao_aprovar | latencia_ms |
| janela_tempo |                |                    |                 |             |

## 03

### MinIO

#### Camada de Armazenamento

##### DATA LAKE CENTRAL

Armazena todos os dados brutos e processados em formato S3-compatible. É o repositório central da plataforma — tanto o histórico de transações quanto os modelos treinados ficam aqui.

##### O QUE É ARMAZENADO

|                      |             |                   |              |                  |
|----------------------|-------------|-------------------|--------------|------------------|
| historico_transacoes | logs_brutos | modelos_ML_v1..vN | dados_treino | resultados_batch |
|----------------------|-------------|-------------------|--------------|------------------|

## 04

### Apache Spark

#### Camada de Processamento

##### ETL + MACHINE LEARNING

Orquestrado pelo Airflow, o Spark processa o histórico de transações armazenado no MinIO **diariamente em batch** para retreinar o modelo de detecção de fraude e gerar agregações analíticas.

##### SAÍDAS DESTA CAMADA

|                    |                     |                   |                      |
|--------------------|---------------------|-------------------|----------------------|
| modelo_retreinado  | features_calculadas | kpi_fraude_diario | perfil_comportamento |
| relatorio_accuracy |                     |                   |                      |

## 05

### PostgreSQL

#### Camada de Consumo

##### DATA WAREHOUSE • BI

Recebe os dados agregados e estruturados do Spark. Alimenta dashboards de BI, relatórios para gestores e APIs de consulta — onde as **decisões de negócio** são tomadas.

##### TABELAS DISPONÍVEIS PARA BI

|                  |           |           |                     |                   |
|------------------|-----------|-----------|---------------------|-------------------|
| fato_fraudes_dia | dim_conta | kpi_canal | taxa_falso_positivo | volume_transacoes |
|------------------|-----------|-----------|---------------------|-------------------|

**1. Associando cada ferramenta à sua camada e função principal:**

- **a.** Qual ferramenta é responsável por **receber os dados em tempo real**? O que aconteceria se ela ficasse fora do ar?
- **b.** Qual a diferença entre o que o **Flink** faz e o que o **Spark** faz? Por que precisamos dos dois?
- **c.** Qual o papel do **MinIO**?
- **d.** Por que o **Airflow** aparece como uma camada separada que "Gerência" todas as outras?

**2. Analise o fluxo de uma transação suspeita**

Imagine que uma transação de **R\$ 47.000** é feita às 3h da manhã de um dispositivo nunca usado antes, para uma conta em outro país. Percorra as 5 camadas e responda:

- **01.** Em qual camada essa transação **entra** na plataforma? Quais variáveis seriam registradas?
- **02.** Em qual camada a **decisão de bloquear ou não** a transação é tomada? Em quanto tempo?
- **03.** Onde essa transação **fica armazenada** para análise futura e retreinamento do modelo?
- **04.** Ao final do dia, onde o gestor consegue ver **quantas fraudes foram bloqueadas**?
- **05.** Se o modelo errar e bloquear uma transação legítima (falso positivo), qual camada precisaria ser ajustada e como?

**3. Objetivo de Negócios Conecte dados e decisões**

- ① "Qual canal (app, internet banking, caixa e outros) tem mais tentativas de fraude?"
- ② "Em qual camada será executado o aprendizado do modelo?"
- ③ "Em qual camada vou disparar Jobs de coletas e tarefas?"
- ④ "Visualização das transações e alertas de fraudes?"

**4. Criar um Organograma básico das áreas do sistema financeiro que serão auditadas, através dessa plataforma de análise, mineração e aprendizado de transações de dados:**

# Estudo técnico Infraestrutura de Dados

Processamento de Dados em Média e Larga Escala

Análise de Dados | Data Mining | Machine Learning

Professor Benir Falcão Pistille

Versão 1.0

Abril 2026