

FATEC VOTORANTIM
Ciência de Dados em Negócios
5º Semestre de Ciência de Dados em Negócios

**Relatório Técnico: Infraestrutura de Dados para Prevenção
de Fraudes**

EQUIPE:

Equipe: Arthur Nunes, Bruno Araujo e Caio César Corrá

Sorocaba/SP

2026

Cenário e Problema de Negócio

Uma grande instituição financeira, com presença nacional e internacional (150 localidades) e uma rede de 2.000 funcionários e parceiros, está enfrentando um alto volume de transações suspeitas e anomalias em seus canais de negócio e investimentos.

O Problema: A arquitetura atual ou a ausência de uma análise em tempo real tem permitido que fraudes ocorram. A empresa necessita de uma plataforma de dados moderna e unificada capaz de coletar, armazenar e analisar dados em altíssima velocidade para detectar e bloquear transações fraudulentas antes que elas sejam concluídas.

Requisitos Críticos de Sucesso (SLAs):

- Latência: Detecção de fraude em menos de 100ms (antes da aprovação da transação).
- Vazão (Throughput): Capacidade para processar mais de 2 milhões de mensagens por segundo.
- Eficácia: 99.5% de precisão nos modelos de Machine Learning.
- Disponibilidade: 99.99% de uptime da plataforma.

Arquitetura da Solução e Ferramentas

Para resolver o problema, foi desenhada uma plataforma de dados moderna baseada em 5 camadas principais, além de uma camada de orquestração transversal, utilizando tecnologias open-source:

Orquestração Transversal (Apache Airflow): Gerencia, agenda e monitora todos os pipelines de dados da plataforma, garantindo que as tarefas ocorram na ordem e no momento corretos.

Camada 01 - Ingestão (Apache Kafka): Porta de entrada dos dados. Recebe transações, logs e cotações em tempo real com altíssima vazão e tolerância a falhas.

Camada 02 - Streaming / Processamento em Tempo Real (Apache Flink): Consome os dados do Kafka instantaneamente. Aplica regras de negócio e consome modelos de Machine Learning (ML) para tomar a decisão de aprovar ou bloquear a transação em menos de 100ms.

Camada 03 - Armazenamento / Data Lake (MinIO): Repositório central seguro (compatível com S3) que armazena dados brutos, histórico de transações, dados de treinamento e os modelos de ML.

Camada 04 - Processamento Batch e ML (Apache Spark): Motor de processamento pesado. Diariamente, varre o histórico no MinIO para retreinar e aprimorar os modelos de detecção de fraude, além de gerar agregações analíticas.

Camada 05 - Consumo / Data Warehouse (PostgreSQL): Banco de dados relacional que recebe os dados já consolidados pelo Spark para alimentar relatórios, Dashboards de BI (Business Intelligence) e APIs para tomada de decisão gerencial.

Resolução do Estudo de Caso

Abaixo estão as respostas e explicações técnicas para as questões levantadas sobre o fluxo de trabalho da plataforma.

1. Associando cada ferramenta à sua camada e função principal

a. Qual ferramenta é responsável por receber os dados em tempo real? O que aconteceria se ela ficasse fora do ar?

- A ferramenta é o Apache Kafka (Camada de Ingestão). O Kafka atua como o sistema nervoso central da mensageria. Se ele ficasse fora do ar, a entrada de novos dados seria interrompida. Como resultado, o Flink não receberia as transações para avaliar, impossibilitando a detecção de fraudes em tempo real. Os sistemas transacionais do banco teriam que negar todas as operações (causando indisponibilidade de negócio) ou aprovar às cegas (aumentando drasticamente o risco de fraudes).

b. Qual a diferença entre o que o Flink faz e o que o Spark faz? Por que precisamos dos dois?

- O Flink atua no processamento em Streaming (fluxo contínuo, tempo real, baixa latência, focado no "agora"), enquanto o Spark atua no processamento Batch (lotes, grande volume de dados históricos, focado no "passado para aprender para o futuro"). Precisamos dos dois porque eles resolvem problemas diferentes. O Flink é necessário para agir em menos de 100ms e bloquear a fraude na hora que ela tenta ocorrer. Já o Spark é necessário para pegar o histórico de meses de transações armazenado no Data Lake, cruzar as informações de forma profunda e retreinar os algoritmos de Machine Learning (atualizando a "inteligência" que o Flink usará no dia seguinte).

c. Qual o papel do MinIO?

- O MinIO atua como a Camada de Armazenamento Central (Data Lake). Ele é o repositório definitivo da empresa. Ele guarda com segurança e baixo custo os dados brutos que chegam do Kafka, os logs, o histórico completo de transações e, muito importante, hospeda os artefatos dos modelos de Machine Learning (versões v1... vN) que serão carregados pelo Flink.

d. Por que o Airflow aparece como uma camada separada que "Gerencia" todas as outras?

- Porque o Airflow não processa nem armazena os dados em si; ele é um orquestrador de processos (agendador de tarefas). Ele controla a dependência e o tempo das ações. Por exemplo, ele garante que o Spark (Camada 04) só comece a retreinar o modelo de Machine Learning à meia-noite, depois que os dados do dia inteiro já foram totalmente gravados no MinIO (Camada 03), e, se houver falha, ele emite alertas para a equipe de engenharia.

2. Análise do fluxo de uma transação suspeita

Cenário: Transação de R\$ 47.000, às 3h da manhã, dispositivo nunca usado, conta em outro país.

01. Em qual camada essa transação entra na plataforma? Quais variáveis seriam registradas?

- Entra na Camada 01 (Apache Kafka). As variáveis registradas seriam as mapeadas na entrada de dados: id_transacao, valor_R\$ (47.000), timestamp (03:00), id_conta_origem, id_conta_destino (internacional), canal, ip_dispositivo (novo), e localizacao_GPS.

02. Em qual camada a decisão de bloquear ou não a transação é tomada? Em quanto tempo?

- Na Camada 02 (Apache Flink), em menos de 100ms. O Flink avalia imediatamente as variáveis recebidas do Kafka cruzando com o modelo_ML em cache e com regras de negócio, gerando um alto score_fraude (devido à hora, valor, dispositivo novo e conta estrangeira) e emitindo a decisao_aprovar como falsa/bloqueada.

03. Onde essa transação fica armazenada para análise futura e retreinamento do modelo?

- Na Camada 03 (MinIO). Independentemente de ter sido aprovada ou bloqueada, ela desce como dado bruto/processado para o Data Lake, compondo o arquivo de historico_transacoes e dados_treino.

04. Ao final do dia, onde o gestor consegue ver quantas fraudes foram bloqueadas?

- Na Camada 05 (PostgreSQL / Data Warehouse), através de Dashboards de BI. O gestor acessará painéis visuais construídos sobre as tabelas fato_fraudes_dia e kpi_canal presentes no PostgreSQL.

05. Se o modelo errar e bloquear uma transação legítima (falso positivo), qual camada precisaria ser ajustada e como?

- A correção de longo prazo (inteligência) ocorre na Camada 04 (Apache Spark), mas a alteração para ação acontece na Camada 02 (Apache Flink). Quando uma transação é marcada como falso positivo pelo atendimento humano, essa informação (rótulo corrigido) é salva no Data Lake (MinIO). No fim do dia, o Spark (Camada 04) usará esse dado corrigido para retreinar o modelo (modelo_retreinado), ensinando a máquina que aquele padrão específico era legítimo. O novo modelo é salvo no MinIO e, em seguida, o Flink (Camada 02) passa a utilizar esta versão atualizada para não cometer o mesmo erro nas próximas transações.

3. Objetivos de Negócios: Conecte dados e decisões

01. "Qual canal (app, internet banking, caixa e outros) tem mais tentativas de fraude?"

- Esta resposta é obtida na Camada 05 (PostgreSQL/BI), consultando a tabela kpi_canal ou agrupando os dados do fato_fraudes_dia pela dimensão de canal.

02. "Em qual camada será executado o aprendizado do modelo?"

- Na Camada 04 (Apache Spark). É onde o processamento pesado de ETL e Machine Learning em batch é realizado.

03. "Em qual camada vou disparar Jobs de coletas e tarefas?"

- Na Camada Transversal de Orquestração (Apache Airflow). Ele é o responsável por engatilhar ("trigger") as tarefas entre as camadas.

04. "Visualização das transações e alertas de fraudes?"

- Através de relatórios, Dashboards de BI e sistemas de mensageria consumidos a partir da Camada 05 (PostgreSQL) para visões agregadas, e APIs possivelmente conectadas às saídas da Camada 02 (Flink) para alertas imediatos operacionais em tempo real.

4. Criar um Organograma básico das áreas do sistema financeiro que serão auditadas, através dessa plataforma de análise, mineração e aprendizado de transações de dados:

