

Nome: Bruno Felipe de Souza Araujo



Exercícios de Estudos de Casos Reais

Datacenter | Mineração de Dados | Telecomunicação

Professor Benir Falcão Pistille

Versão 1 | Maio 2026



Parte I: Questões de Múltipla Escolha

Instruções: Cada questão possui apenas uma alternativa correta. Assinale a opção que melhor responde ao enunciado.

Questão 1.Arquitetura Lakehouse

A DataFlow Cloud Solutions implementou uma arquitetura Lakehouse que combina a flexibilidade de um data lake com a performance e governança de um data warehouse. Com base no estudo de caso, analise as afirmações a seguir e identifique a tecnologia que atua como object store S3-compatible na camada de armazenamento:

- a)Apache Kafka - utilizado como message broker para streaming de eventos em tempo real.
- b)Apache Airflow - responsável pela orquestração de workflows e DAGs.
- ☒ c)MinIO - object store compatível com API S3, utilizado para armazenar dados em formato Parquet com Delta Lake.
- d)PostgreSQL - data warehouse relacional para consultas analíticas e metadados.
- e)Apache Flink - motor de processamento de streams em tempo real.

Questão 2.Processamento Batch vs Streaming

A plataforma da DataFlow utiliza uma abordagem híbrida de processamento. O Apache Spark é empregado para processamento batch em larga escala, enquanto o Apache Flink processa streams em tempo real. Sobre essas duas tecnologias, é correto afirmar que:

- a)O Apache Spark processa eventos individualmente com latência sub-segundo, enquanto o Flink utiliza micro-batches.
- b)O Apache Flink processa eventos individualmente, proporcionando latência verdadeiramente em tempo real, diferente do Spark Streaming que utiliza micro-batches.
- ☒ c)Ambos utilizam a mesma abordagem de micro-batches para processamento de streams.
- d)O Spark é exclusivo para processamento de grafos (GraphX) e não suporta ETL em larga escala.
- e)O Flink é utilizado apenas para treinamento de modelos de machine learning distribuído.

Questão 3.Apache Kafka na Arquitetura de Dados

O Apache Kafka é descrito como a espinha dorsal da plataforma de streaming da DataFlow. Com base nas características apresentadas no estudo de caso, qual das seguintes funcionalidades NÃO é atribuída ao Kafka na arquitetura implementada?

- a)Pub/Sub distribuído com replicação de partições.
- b)Retenção configurável de mensagens.
- ☒ c)Execução de algoritmos de machine learning distribuído (MLlib).
- d)Integração nativa com Spark Streaming e Flink.
- e)Kafka Connect para integração com sistemas externos.

Questão 4. Tecnologias Python para Machine Learning

O ecossistema Python é amplamente utilizado para análise de dados e ML na plataforma da DataFlow. Com base na Tabela 3 do estudo de caso, qual biblioteca é responsável pelo gerenciamento do ciclo de vida de modelos de machine learning, incluindo versionamento e monitoramento?

- a) scikit-learn - algoritmos clássicos de machine learning.
- b) pandas - manipulação e análise de dados.
- c) TensorFlow/PyTorch - deep learning e redes neurais.
- ☒ d) MLflow - gerenciamento do ciclo de vida de modelos ML.
- e) Great Expectations - validação e qualidade de dados.

Questão 5. Casos Reais - Netflix

A Netflix opera uma das maiores infraestruturas de dados do mundo. Segundo o estudo de caso, o pipeline Keystone da Netflix processa diariamente:

- a) Até 1 petabyte de dados de entrada e 3 petabytes de saída.
- b) Até 3 petabytes de dados de entrada e 7 petabytes de saída.
- c) Até 5 petabytes de dados de entrada e 10 petabytes de saída.
- ☒ d) Até 500 terabytes de dados de entrada e 1 petabyte de saída.
- e) Até 10 petabytes de dados de entrada e 15 petabytes de saída.

Questão 6. Inovações da Uber em Kafka

A Uber desenvolveu melhorias significativas no Kafka e Flink para atender suas necessidades de escala. Qual das seguintes tecnologias foi desenvolvida pela Uber para replicação cross-datacenter de mensagens Kafka?

- a) Cluster Federation - distribuição de dados em clusters menores.
- ☒ b) uReplicator - replicação cross-datacenter de mensagens Kafka.
- c) FlinkSQL - camada SQL para processamento de streams.
- d) Apache Pinot - analytics em tempo real para dashboards.
- e) Kappa+ Architecture - reprocessamento de dados históricos.

Questão 7.Resultados da Modernização

A implementação da plataforma moderna trouxe resultados significativos para a DataFlow. De acordo com a Tabela 5 do estudo de caso, qual foi a redução percentual na latência de processamento após a modernização?

- a) 50% de redução, passando de 4-6 horas para 2-3 horas.
- b) 75% de redução, passando de 4-6 horas para 1 hora.
- c) 90% de redução, passando de 4-6 horas para 20-30 minutos.
- ☒ d) 99% de redução, passando de 4-6 horas para menos de 10 segundos.
- e) 85% de redução, passando de 4-6 horas para 5 minutos.

Questão 8.Arquitetura de Data Mining em E-Commerce

No estudo técnico de Mineração de Dados em E-Commerce, o Data Mining App desenvolvido em Python/Flask e responsável por diversas funções. Qual das seguintes NAO é uma responsabilidade do Data Mining App segundo o estudo?

- a) Coleta de dados de diversas fontes como históricos de compras e logs de navegação.
- b) Pre-processamento incluindo limpeza, transformação e normalização dos dados.
- c) Execução de algoritmos de mineração de dados (classificação, cauterização, associação, regressão).
- ☒ d) Geração de descrições de produtos e respostas a perguntas frequentes usando GPT-4.
- e) Exposição de APIs para consumo dos resultados da mineração.

Questão 9.Hugging Face no E-Commerce

O Hugging Face, com seus modelos Transformers, e integrado para lidar com tarefas de Processamento de Linguagem Natural (PLN) no cenário de E-Commerce. Qual aplicação do Hugging Face é utilizada para identificar informações relevantes como nomes de produtos, locais e datas em textos não estruturados?

- a) Análise de Sentimento.
- b) Classificação de Texto.
- ☒ c) Extração de Entidades Nomeadas (NER).
- d) Modelagem de Tópicos.
- e) Geração de Conteúdo.

Questão 10. OpenAI API - Busca Semântica

A integração com a API da OpenAI eleva as capacidades de IA da arquitetura de E-Commerce. A funcionalidade de Busca Semântica permite:

- a) Apenas busca por palavras-chave exatas no catálogo de produtos.
- Busca interna do e-commerce baseada no significado das consultas, não apenas em palavras-chave exatas.
- c) Indexação de logs e eventos para busca full-text.
- d) Replicação cross-datacenter de mensagens.
- e) Monitoramento de KPIs em tempo real.




Figura 1: Arquitetura de Data Mining - Plataforma Moderna de Dados (Lakehouse)

Questão 11. Cloud ML - Ciclo de Vida de Modelos

Os serviços de Machine Learning na nuvem (AWS SageMaker ou Google Cloud Vertex AI) são utilizados para o ciclo de vida completo de modelos de ML. Qual funcionalidade permite automatizar o processo de construção de modelos, acelerando o desenvolvimento?

- a) Treinamento de Modelos.
- b) Implantação de Modelos.
- c) Gerenciamento de Modelos.
- AutoML.
- e) Feature Store.

Questão 12. Kubernetes e Monitoramento

Na arquitetura de E-Commerce, o Kubernetes e o Prometheus/Grafana desempenham papéis complementares. Sobre essas tecnologias, é correto afirmar que:

- a) O Prometheus visualiza métricas em dashboards interativos, enquanto o Grafana coleta métricas dos componentes.
- b) O Kubernetes coleta métricas de uso de CPU e memória, enquanto o Prometheus gerencia a implantação de containers.
- ☒ c) O Kubernetes gerencia a implantação, escalonamento e operação de aplicações containerizadas, enquanto o Prometheus coleta métricas e o Grafana as visualiza em dashboards.
- d) O Grafana é responsável pela orquestração de containers e o Kubernetes por criar dashboards.
- e) O Prometheus é um banco de dados relacional para armazenamento de features para ML.

Questão 13. Arquitetura de Data Mining para Telecom

No estudo de caso de Data Mining em Telecomunicações, a arquitetura de armazenamento segue o modelo de Data Lakehouse. Quais tecnologias garantem transações ACID sobre o data lake?

- a) HDFS e MinIO apenas.
- b) Apache Hive e PrestoDB.
- ☒ c) Delta Lake e Apache Iceberg.
- d) Redis e Cassandra.
- e) Elasticsearch e Logstash.

Questão 14. Pipeline de ML em Telecom

O pipeline de ML no setor de telecomunicações é organizado em três casos de uso principais. Qual algoritmo é utilizado para predição de churn, alcançando $AUC=0.92$ e $precision@5\%=0.96$?

- a) Isolation Forest.
- b) Autoencoders.
- ☒ c) XGBoost.
- d) LightGBM.
- e) Random Forest exclusivamente, sem outras técnicas.

Questão 15. Detecção de Anomalias de Rede

Para detecção de anomalias em KPIs de células (RSRP, SINR, taxa de queda, throughput), o estudo de caso telecom utiliza:

- a) Apenas XGBoost sobre dados históricos de CDRs.
- ☒ b) Isolation Forest e autoencoders para detecção em tempo real.
- c) Apenas regras estáticas baseadas em thresholds fixos.
- d) Apache Spark SQL para consultas ad-hoc.
- e) Modelos de regressão linear simples.




Figura 2: Arquitetura de Análise de Dados - E-Commerce Inteligente

Questão 16. Propensão a Upsell

O modelo de propensão a upsell/cross-sell utiliza LightGBM para prever a probabilidade de aceite de ofertas. Segundo o estudo, campanhas direcionadas ao top 10% de propensão geram qual incremento percentual no ARPU (Average Revenue Per User)?

- a) +5%
- b) +8%
- c) +12%
- ☒ d) +18%
- e) +25%

Questão 17.Arquitetura Lambda

A arquitetura adota Lambda Architecture, combinando batch e streaming. Sobre essa arquitetura, é correto afirmar que:

- a)O batch processing é usado apenas para detecção de anomalias e alertas operacionais.
- b)O streaming é usado para treino de modelos e relatórios históricos.
- ☒ c)O batch processa petabytes de CDRs em HDFS para treino de modelos e relatórios históricos, enquanto o streaming processa milhões de eventos/segundo com latência sub-segundo.
- d)A view unificada é exposta apenas via APIs REST, sem dashboards.
- e)Apache Superset é utilizado exclusivamente para streaming de dados.

Questão 18.Caso Vodafone

A Vodafone implementou uma estratégia de AI e GenAI em parceria com Google Cloud. Qual resultado planejado foi mencionado no estudo de caso?

- a)Redução de 30% no MTTR de falhas de rede.
- b)50% de redução planejada em ferramentas OSS.
- c)Precision de 96% na identificação de churners.
- d)90% de economia em pipelines CI/CD.
- ☒ e)Aumento de 12-18% em ARPU por campanhas direcionadas.

Questão 19.MLOps e Governança

Na camada de Governança e MLOps da arquitetura telecom, qual ferramenta é responsável por versionar experimentos, modelos e parâmetros?

- a)DVC (Data Version Control).
- b)Great Expectations.
- ☒ c)MLflow.
- d)Evidently AI.
- e)Apache Airflow.

Questão 20. Infraestrutura Multicloud

A arquitetura multicloud é projetada para evitar lock-in de fornecedor, maximizar disponibilidade e otimizar custos. Qual ferramenta é utilizada para provisionar recursos em AWS, Azure, GCP e OpenStack com estado compartilhado?

- a) Ansible.
- b) Helm.
- ☒ c) Terraform.
- d) ArgoCD.
- e) Jenkins.




Figura 3: Arquitetura de Aprendizado de Máquina - Telecom Multicloud

Parte II: Questões Verdadeiro ou Falso

Instruções: Avalie cada afirmação como VERDADEIRO (V) ou FALSO (F). Justifique mentalmente com base nos estudos de caso.

Processo de Data Mining - Ciclo CRISP-DM




Figura 4: Processo de Data Mining - Ciclo CRISP-DM

1. A arquitetura Lakehouse da DataFlow combina MinIO como data lake com PostgreSQL como data warehouse, unindo flexibilidade e governança. Resposta: (V)
2. O Apache Spark Streaming processa eventos individualmente com latência verdadeiramente em tempo real, diferente do Apache Flink que utiliza micro-batches. Resposta: (F)
3. O Schema Registry (Confluent) é responsável pelo gerenciamento de esquemas Avro na camada de ingestão da plataforma DataFlow. Resposta: (V)
4. A Netflix utiliza Apache Flink para treinamento de modelos de recomendação e Apache Spark para processamento em tempo real de personalização. Resposta: (F)
5. A arquitetura Kappa+ da Uber permite reprocessamento de dados históricos sem modificar o código de processamento. Resposta: (V)
6. O Data Mining App em Python/Flask do cenário E-Commerce é responsável por gerar descrições de produtos usando GPT-4 e embeddings da OpenAI. Resposta: (F)
7. O API Gateway na arquitetura E-Commerce funciona como ponto de entrada unificado, realizando roteamento, segurança, balanceamento de carga e monitoramento. Resposta: (V)

8.O Cloud ML (SageMaker/Vertex) é utilizado exclusivamente para treinamento de modelos e não oferece funcionalidades de deploy ou AutoML. Resposta: (**F**)

9.Na arquitetura telecom, Apache NiFi gerencia fluxos de dados complexos com routing, transformação e proveniência em tempo real. Resposta: (**V**)

10.O modelo de churn prediction na operadora asiática utiliza HDFS para storage, Spark SQL para engenharia de features, e Random Forest/GBDT para classificação. Resposta: (**V**)

11.A Ericsson utiliza Cloud Container Distribution (CCD) baseada em Kubernetes para produtos 5G Core, reduzindo tempo de feedback de semanas para horas. Resposta: (**V**)

12.O service mesh Istio adiciona overhead de comunicação entre micro serviços, mas habilita mTLS, traffic splitting e observabilidade. Resposta: (**V**)

13.A camada de armazenamento da DataFlow utiliza formato JSON para dados curados no data lake, sem suporte a transações ACID. Resposta: (**F**)

14.O Prometheus + Grafana são utilizados para coleta e visualização de métricas, enquanto o Jaeger é responsável por distributed tracing de micro serviços. Resposta: (**V**)

15.A operadora asiática mencionada no estudo processa 2.3 TB de novos dados por dia, com 97% provenientes de dados OSS (Operations Support Systems). Resposta: (**V**)

Exercícios Estudos de Casos Reais

Datacenter | Mineração de Dados | Telecomunicação

Professor Benir Falcão Pistille

Maio de 2026